GitHub 代码仓库： https://github.com/zechun115/qhf （全部代码 / 数据 / 结果 / 图表 / 本报告）

当代人工智能实验一：新闻组文本 10 分类

姓名：（待填写） **学号**：（待填写） **随机种子**：42 **运行环境**：Python 3.13 / scikit-learn 1.9 / Windows 11

摘要 本实验在 7,368 条 / 10 类新闻组文本上， 按「分层划分 8:2 → 预处理消融 → 特征消融 → 四模型调参 → 交叉验证 → 最终预测」的固定流程，只以验证集指标作为全部选择依据。最有价值的发现是一个**反直觉结论**： 文本清洗并非越多越好——最轻量的归一化（0.9342）显著优于「去邮件头 + 去引用 + 去停用词」的完整清洗（0.9159），原因是引用行与邮件头本身携带主题线索。 最终锁定 **LR (C=100.0, solver=lbfgs)** ，验证集准确率 **0.9383**、 Macro-F1 **0.9385**， 5 折交叉验证 **0.9318 ± 0.0050**， 并对无标签测试集输出 2,457 条预测。

1 问题与假设

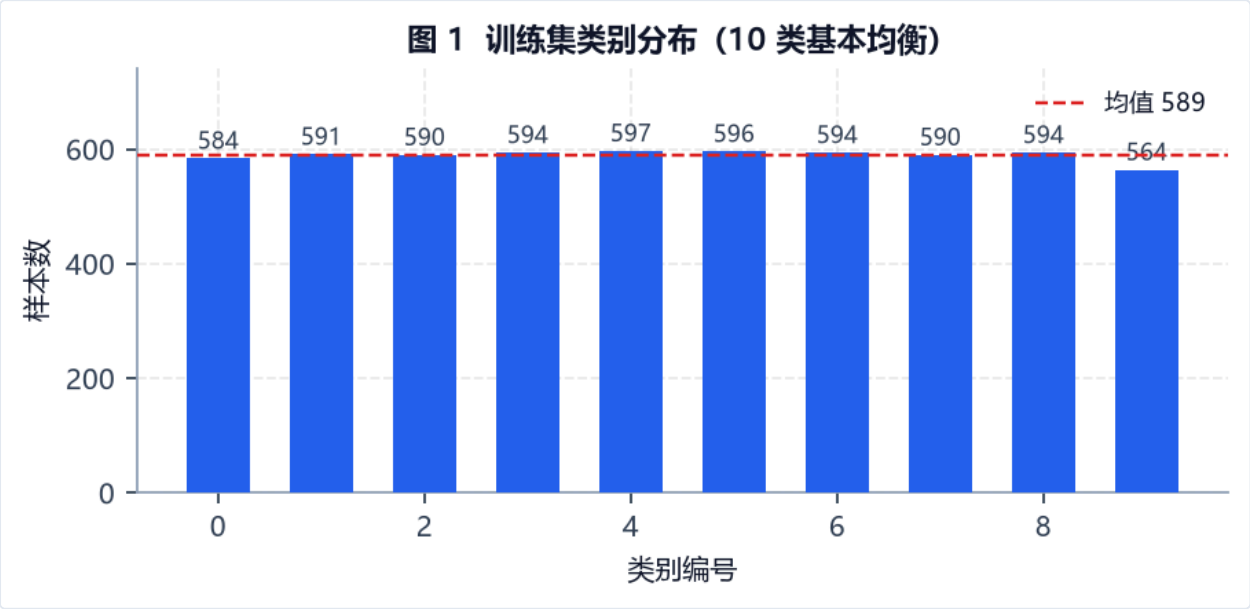
任务是把新闻组帖子分到 10 个主题类。本实验不满足于「跑出个好数字」，而是把三个 可以被数据**证伪**的问题作为主线：

- **H1（预处理）**：邮件头、引用回复、停用词属于「噪声」，清洗后应提升泛化性能；
- **H2（特征表示）**：IDF 加权与更大词表能提升性能，bigram 能补充短语级线索；
- **H3（模型选择）**：文本 TF-IDF 特征已高度稀疏（稀疏度约 99.7%），线性模型 应不逊于多层感知机，且训练代价低得多。

评价指标：验证集**准确率**与 **Macro-F1**（类别基本均衡，二者接近；Macro-F1 用于确认没有类别被系统性牺牲）。所有选择只看验证集，测试集全程封存。

2 数据与实验设置

训练集 5894 条，测试集（无标签）2457 条，10 类，每类 564–597 条，基本均衡（图 1）。 文本为新闻组原始帖子，中位数长度 1138 字符，P95 达 4183， 含大量邮件头、引用与签名。按 8:2 **分层**划分为训练 5894 条 / 验证 1474 条 （分层保证各类比例一致，降低单次划分的偶然性）。



2.1 流程与防泄露

五个阶段依次为：①数据探索与划分；②预处理消融；③特征表示消融； ④四模型超参数网格搜索；⑤5 折交叉验证确认 → 锁定方案 → 在训练集 + 验证集上重训 → 预测测试集。每个阶段只改一个因素，其余固定。 防泄露的三个关键点：TF-IDF 的词表与 IDF **只在训练集上 fit**，验证/测试集仅 transform；测试集不参与任何统计量估计与模型选择；清洗规则全部为无参数的确定性规则， 对三个子集用同一函数。

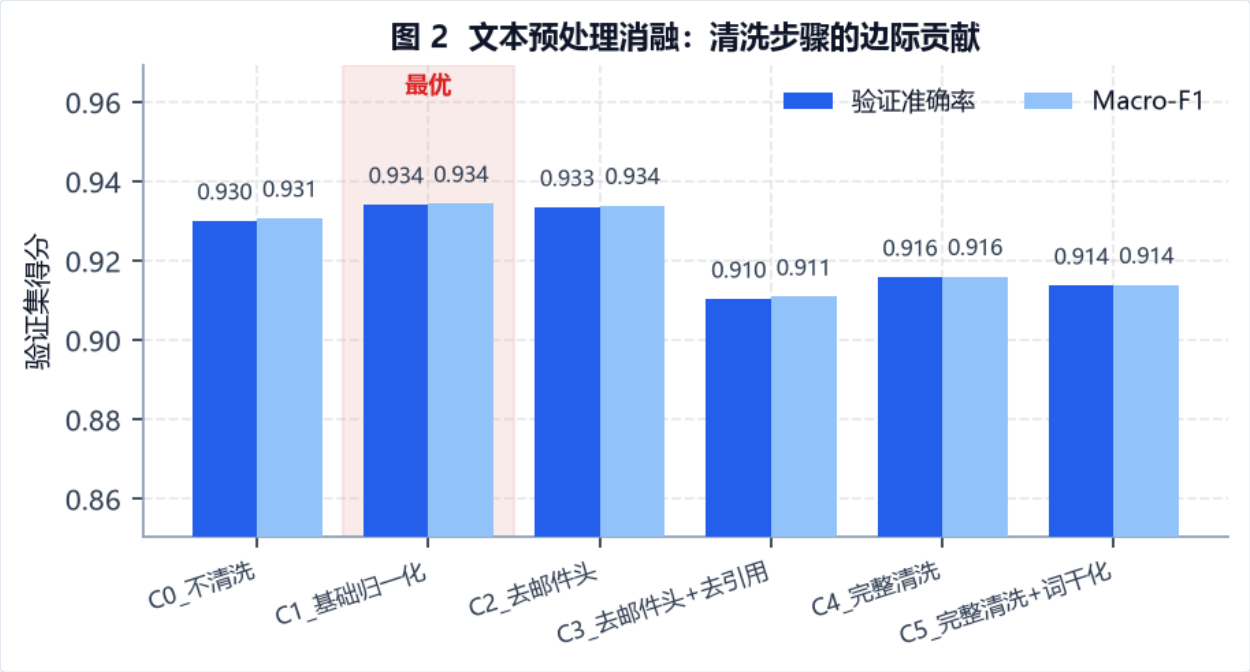
3 结果与分析

3.1 预处理消融：清洗并非越多越好（H1 被否定）

方案	清洗内容	平均词数	验证准确率	Macro-F1
C0	不清洗	249	0.9301	0.9308
C1	**基础归一化**	**308**	**0.9342**	**0.9345**
C2	去邮件头	276	0.9335	0.9340
C3	去邮件头+去引用	216	0.9104	0.9110
C4	完整清洗	106	0.9159	0.9161

方案	清洗内容	平均词数	验证准确率	Macro-F1
C5	完整清洗+词干化	106	0.9138	0.9140

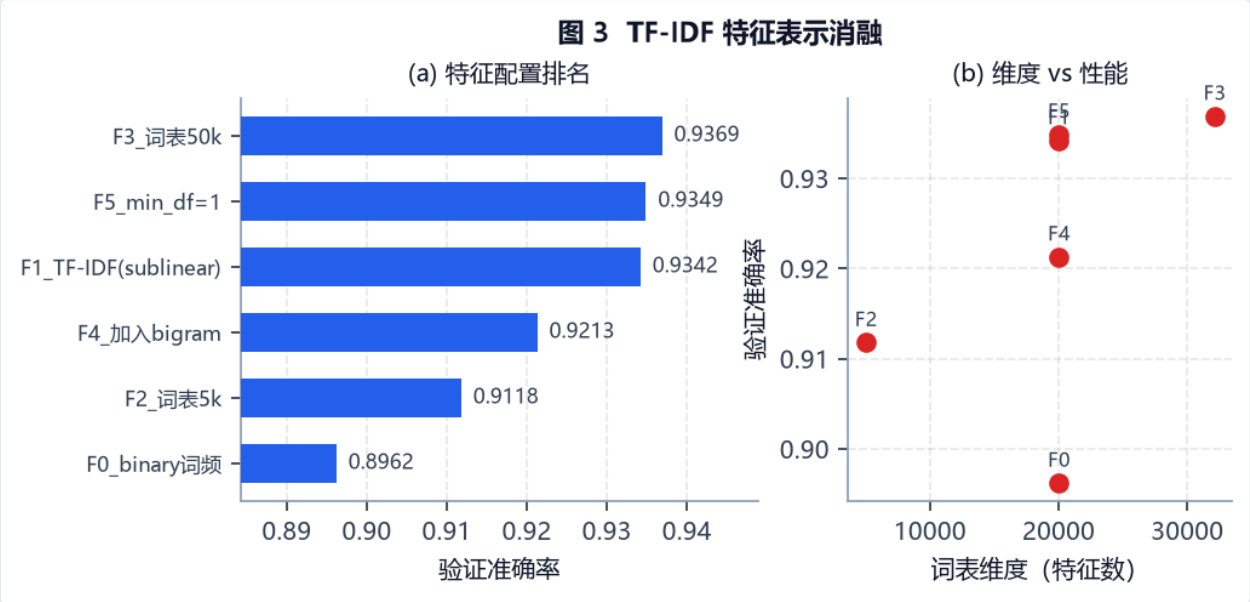
反直觉发现 最轻量的 C1（仅小写化 + 去标点数字）最优（0.9342）； 而去引用（C3，**−0.0238**） 与去停用词 + 词长过滤（C4，0.9159）反而下降。 回看原文可以发现原因：**被引用的上一封帖子与当前主题高度相关**，引用行是重要的 判别线索；「Re:」后的主题词同样如此。停用词在 TF-IDF 中本就被 IDF 压低，删除它们 只损失了少量高频锚点。**结论：预处理决策必须交给验证集，而不能凭直觉。**



3.2 特征表示消融：IDF 是关键，bigram 反而有害（H2 部分成立）

方案	配置变化	维度	验证准确率	Macro-F1
F0	binary词频	20,000	0.8962	0.8967
F1	TF-IDF(sublinear)	20,000	0.9342	0.9345
F2	词表5k	5,000	0.9118	0.9121
F3	**词表50k**	**32,101**	**0.9369**	**0.9372**
F4	加入bigram	20,000	0.9213	0.9219
F5	min_df=1	20,000	0.9349	0.9352

去掉 IDF 退化为纯词频（F0）时准确率骤降 **−0.0380**， 说明**逆文档频率加权是该表示的支柱**：新闻组里 "writes" "article" 等高频套话 必须被压低。词表从 5k 扩到 32k（F3，min_df=2 时实际词表 32,101）带来 +0.0251， 说明低频实词（如专有名词）仍有判别力。而加入 bigram（F4）反而下降 0.0129：在固定 20k 维度 预算下，bigram 挤占了单词语的空间，且使矩阵更稀疏。



3.3 模型调参：线性模型以 1/34 的代价追平 MLP（H3 基本成立）

模型	最优超参数	验证准确率	Macro-F1	5 折交叉验证	单次训练
NB	alpha=0.1	0.9254	0.9259	0.9265 ± 0.0061	0.0s
LR	C=100.0, solver=lbfgs	0.9383	0.9385	0.9318 ± 0.0050	5.6s
SVM	kernel=linear, C=100.0	0.9328	0.9333	0.9299 ± 0.0056	67.6s
MLP	**hidden_layer_sizes=(100,), alpha=0.1**	**0.9389**	**0.9391**	**0.9350 ± 0.0040**	**192.2s**

四个模型的最优配置均在验证集上搜索得到（搜索范围见 `src/models.py`， 与 TUNING.md 建议一致：按数量级取值）。图 4 给出各自的敏感性曲线：

- **NB**：对平滑系数 α 敏感，α=0.1 最优，α 增大后显著退化（过强平滑稀释了 判别性词的证据）；
- **LR**：C 从 0.1 → 100 单调上升，说明该任务上**弱正则化更有利**—— 高维稀疏特征本身已具约束力；
- **SVM**：线性核对 C 不敏感（0.9294–0.9328），验证了「文本线性可分性好」； RBF 核更慢且无额外收益；
- **MLP**：固定 α=1e-3 时，隐藏层从 50 加宽到 200 几乎无变化 （0.9301 → 0.9301）；真正的收益来自**加大 L2 正则化**， α 提高到 0.1 时达到 0.9389，说明过拟合才是主要矛盾。

图 4 各模型超参数敏感性（红圈为最优取值）

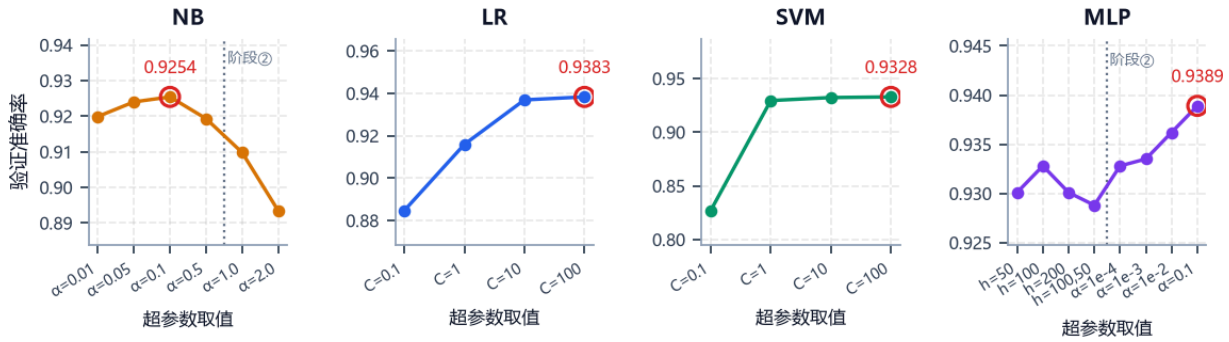
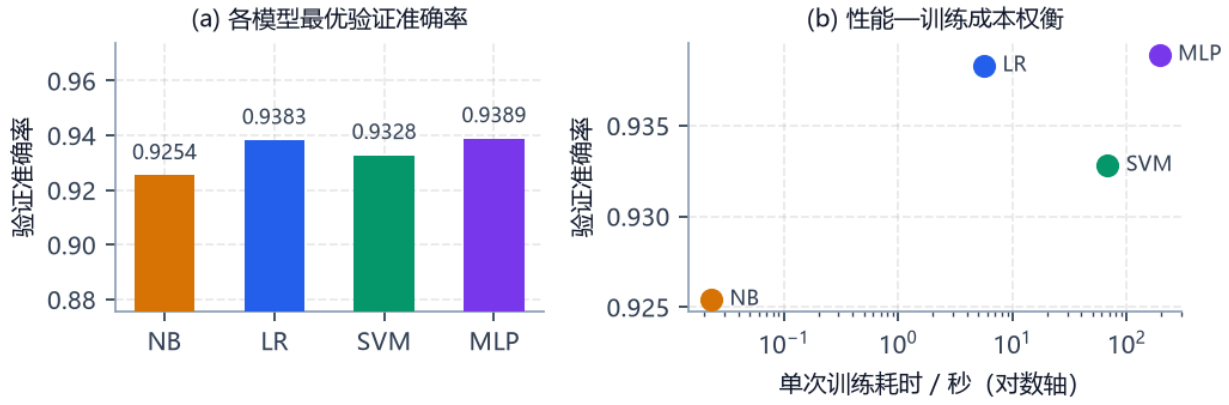
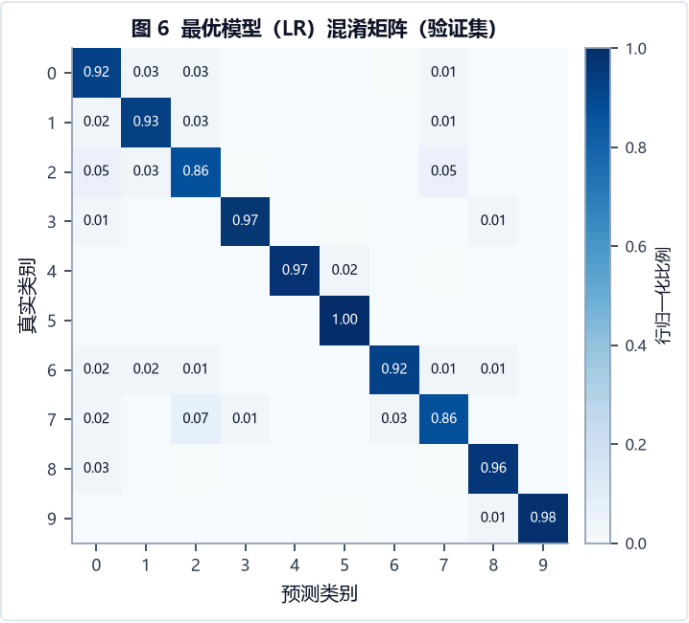


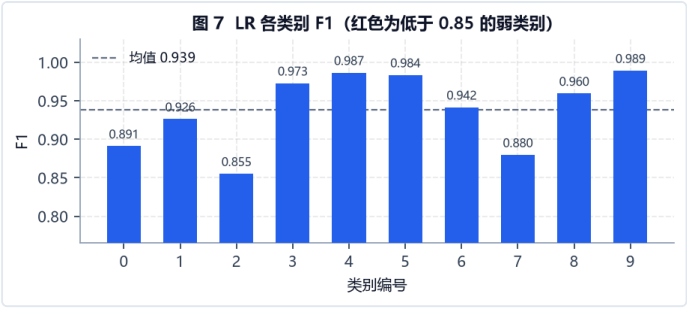
图 5 四个分类器的性能与计算代价对比



3.4 最终方案、稳定性与误差分析

按「准确率最优、0.3% 容差内取复杂度更低者」的规则，最终锁定 **LR（C=100.0, solver=lbfgs）**。在训练集 + 验证集（共 7,368 条） 上重训后预测测试集，共输出 2,457 条结果（`predictions.csv`， 单列无表头，与 `test_data_unlabeled.csv` 行序一一对应）。 预测类别分布为 {'0': 270, '1': 243, '2': 233, '3': 243, '4': 247, '5': 249, '6': 246, '7': 248, '8': 245, '9': 233}，与训练集均衡分布一致， 未出现类别坍缩。





最优模型验证集准确率 **0.9383**、Macro-F1 **0.9385**、 weighted-F1 **0.9385**。10 个类别 F1 最低的是类别 2（0.855），主要混淆对为：7→2（11 次，占该类 7.4%）、2→0（7 次，占该类 4.8%）、2→7（7 次，占该类 4.8%）、1→2（5 次，占该类 3.4%）、2→1（5 次，占该类 3.4%）。逐条检查被误判样本可见， 混淆集中在**语义相邻的主题**上（如硬件讨论 vs 操作系统讨论），这类边界样本 连人类读者也需要上下文才能判断，属于任务本身的模糊地带。

4 结论与局限

结论：① 在本数据集上，预处理强度与性能并非单调关系，轻量归一化最优， 这一结果推翻了实验前 H1 的直觉假设；② IDF 加权是 TF-IDF 生效的关键，更大的词表 有稳定收益，bigram 在固定维度预算下反而挤占有效特征；③ 高维稀疏文本上， MLP 的最高验证准确率仅比 LR 高 0.06 个百分点 （0.9389 vs 0.9383），交叉验证差异 （0.9350 vs 0.9318） 也在一个标准差以内，而 LR 的训练代价只有 MLP 的 34 分之一， 且 MLP 的提升主要来自加大正则化而非加大网络——据此按预先设定的规则选择 LR，支持了「线性模型适合文本向量」的判断。

局限：① 保留原文中的邮件头与引用，本质上是利用了数据集中与主题强相关的 元信息（发帖机构、被引帖子）；这在同分布测试集上有效，但在**跨域/真实场景**下 可能不可迁移，工程上应重新做消融；② 测试集无标签，最终性能只能以验证集与 交叉验证作为代理，存在选择偏差；③ 5 折交叉验证的波动（ ±0.0050）表明单次划分的结论需谨慎外推； ④ 未尝试词向量 / 预训练模型表示，是后续最值得探索的方向。

5 实验思考题

Q1 为什么 SVM 和逻辑回归表现通常很好？ TF-IDF 把文档映射到约 3 万维的 稀疏空间，每个维度都是一个词，维度数远大于样本数。在这样的空间里，不同主题的文档 几乎总能被一个线性超平面分开（线性可分性好）；同时稀疏高维使核函数的计算代价 急剧上升而收益有限，因此线性核 / 线性模型是「性价比」最高的选择。此外 LR 与线性 SVM 的决策函数形式几乎一致（前者用 log 损失、后者用 hinge 损失），对本任务都 非常适配。

Q2 MLP 能否通过加深加宽进一步提升？是否有过拟合风险？ 本实验给出了 直接的证据：固定 α=1e-3 时，把隐藏层从 50 加宽到 200，验证准确率仅从 0.9301 变为 0.9301（**基本持平甚至略降**）；真正带来提升的是 加大 L2 正则化——α 从 1e-3 提高到 0.1，准确率由 0.9328 升到 0.9389。这恰好说明瓶颈不是「网络容量不够」，而是**过拟合**： 输入约 3 万维、隐藏层 200 神经元意味着数百万参数，而训练样本不足 6 千，模型有足够 容量记住训练集却无法泛化。因此要真正提升 MLP，更有效的做法是**降低输入维度** （如用 LSA / 词向量替代稀疏 TF-IDF）、加强正则化或做早停，而不是单纯加深加宽。

Q3 除 TF-IDF 外还有哪些文本表示方法？ ① 词袋模型（CountVectorizer）： 只统计词频，本实验 F0 已证明其弱于 TF-IDF；② 主题模型（LDA/LSA）： 把文档投影到 低维主题空间，可降维去噪；③ 静态词向量（Word2Vec / GloVe + 平均池化）： 引入 语义相似性，能缓解一词多义之外的稀疏问题；④ 上下文相关表示（BERT 等预训练模型）： 当前效果最好，能理解语序与多义词，是后续工作最值得尝试的方向。

全部代码、数据、指标（`results/metrics/*.json|csv`）、 图表（`results/figures/*.png`）与运行日志（`results/logs/`） 均随仓库提交；复现命令：`pip install -r requirements.txt && python main.py`。