GitHub 代码仓库： https://github.com/zechun115/qhf （全部代码 / 数据 / 结果 / 图表 / 本报告）

当代人工智能实验一：新闻组文本 10 分类

姓名：邱浩峰 **学号**：10245501462 **随机种子**：42 **环境**：Python 3.13 / scikit-learn 1.9 / Windows 11

摘要 在 7,368 条 / 10 类新闻组文本上，按「分层 8:2 划分 → 预处理消融 → 特征消融 → 四模型调参 → 交叉验证 → 预测」的固定流程，**只以验证集指标**做全部选择。 最有价值的发现是一个反直觉结论：**清洗并非越多越好**——最轻量归一化（0.9342）显著优于 「去邮件头 + 去引用 + 去停用词」的完整清洗（0.9159），因为引用行与邮件头本身携带主题线索。 最终按事先设定的规则锁定 **LR（C=100.0, solver=lbfgs）**，验证准确率 **0.9383**、Macro-F1 **0.9385**， 5 折交叉验证 **0.9318 ± 0.0050**， 并对无标签测试集输出 2,457 条预测。

1 问题与假设

任务是把新闻组帖子分到 10 个主题类。本实验把三个**可被数据证伪**的问题作为主线， 每个假设都配一个只改单一因素的对照：

- **H1（预处理）**：邮件头、引用回复、停用词属于噪声，清洗后应提升泛化性能；
- **H2（特征表示）**：IDF 加权与更大词表能提升性能，bigram 能补充短语级线索；
- **H3（模型选择）**：TF-IDF 特征高度稀疏（稀疏度 99.7%），线性模型应不逊于 MLP， 且训练代价低得多。

评价指标为验证集**准确率**与 **Macro-F1**（类别均衡，二者接近；后者用于确认没有类别被 系统性牺牲）。所有选择只看验证集，测试集全程封存。

2 数据与实验设置

训练集 5894 条、无标签测试集 2457 条、10 类，每类 564–597 条，基本均衡； 文本中位数长度 1138 字符，含大量邮件头、引用与签名。按 8:2 **分层**划分为训练 5894 条 / 验证 1474 条（分层使各类比例一致，降低单次划分的偶然性）。 流程为五个阶段，每阶段只改一个因素：①划分 → ②预处理消融 → ③特征消融 → ④四模型网格搜索 → ⑤5 折交叉验证确认 → 锁定 → 训练集 + 验证集重训 → 预测测试集。**防泄露**三要点： TF-IDF 词表与 IDF **只在训练集 fit**，验证/测试仅 transform；测试集不参与任何统计量估计与 模型选择；清洗规则均为无参数的确定性规则，三个子集共用同一函数。

3 结果与分析

3.1 预处理消融：清洗并非越多越好（H1 被否定）

方案	清洗内容	平均词数	验证准确率	Macro-F1
C0	不清洗	249	0.9301	0.9308
C1	**基础归一化**	**308**	**0.9342**	**0.9345**
C2	去邮件头	276	0.9335	0.9340
C3	去邮件头+去引用	216	0.9104	0.9110
C4	完整清洗	106	0.9159	0.9161
C5	完整清洗+词干化	106	0.9138	0.9140

反直觉发现 最轻量的 C1（小写化 + 去标点数字）最优（0.9342）； 而增加去引用（C3，**+0.0238**） 或去停用词 + 词长过滤（C4，0.9159）反而下降。回看原文可解释原因： **被引用的上一封帖子与当前主题高度相关**，引用行是重要判别线索，「Re:」后的主题词同理； 停用词在 TF-IDF 中已被 IDF 压低，删除只损失了少量高频锚点。**结论：预处理决策必须由验证集裁定。**

3.2 特征表示消融：IDF 是支柱，bigram 反而有害（H2 部分成立）

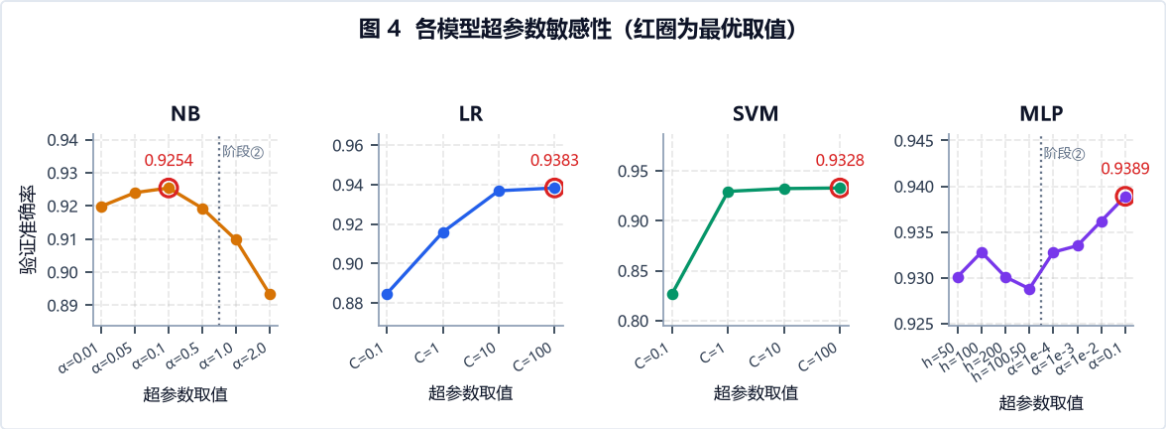
方案	配置变化	维度	验证准确率	Macro-F1
F0	binary词频	20,000	0.8962	0.8967
F1	TF-IDF(sublinear)	20,000	0.9342	0.9345
F2	词表5k	5,000	0.9118	0.9121
F3	**词表50k**	**32,101**	**0.9369**	**0.9372**
F4	加入bigram	20,000	0.9213	0.9219
F5	min_df=1	20,000	0.9349	0.9352

去掉 IDF 退化为纯词频（F0）后准确率骤降 **+0.0380**， 说明**逆文档频率加权是该表示的支柱**：新闻组里 "writes" "article" 等高频套话必须被压低。 词表从 5k 扩到 32k 带来 +0.0251， 说明低频实词（专有名词等）仍有判别力；而加入 bigram（F4）反而下降 +0.0129——在固定 20k 维度预算下，bigram 挤占了单词特征的空间并进一步稀疏化矩阵。

3.3 模型调参：线性模型以 1/34 的代价追平 MLP（H3 基本成立）

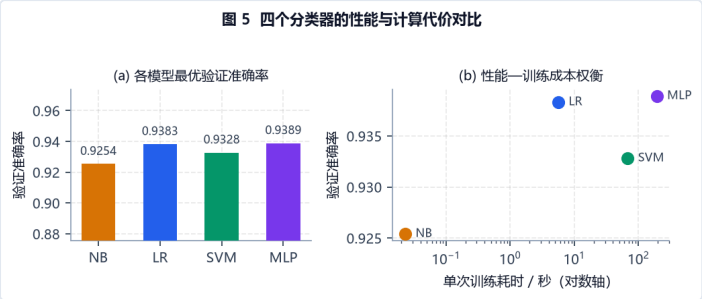
模型	最优超参数	验证准确率	Macro-F1	5 折交叉验证	单次训练
NB	alpha=0.1	0.9254	0.9259	0.9265±0.0061	0.0s
LR	C=100.0, solver=lbfgs	0.9383	0.9385	0.9318±0.0050	5.6s
SVM	kernel=linear, C=100.0	0.9328	0.9333	0.9299±0.0056	67.6s
MLP	**hidden_layer_sizes=(100,), alpha=0.1**	**0.9389**	**0.9391**	**0.9350±0.0040**	**192.2s**

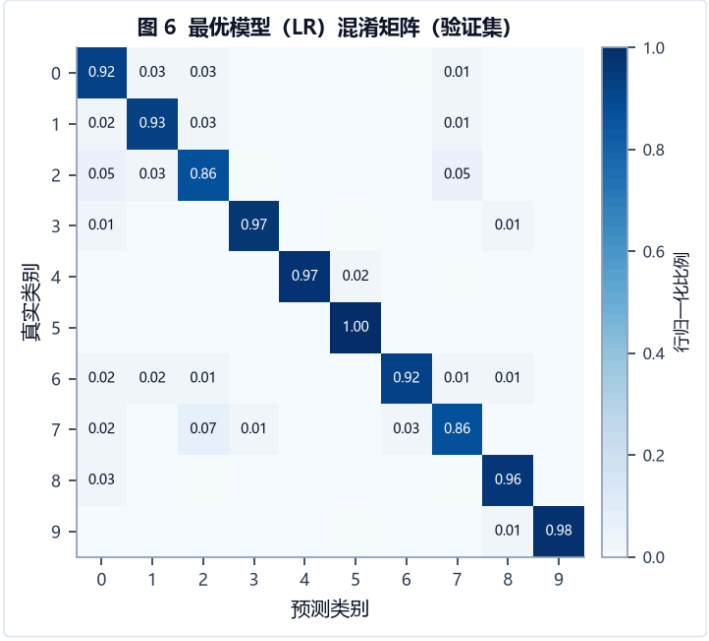
- **NB**：对平滑系数 α 敏感，α=0.1 最优，继续增大显著退化（过强平滑稀释了判别性词的证据）；
- **LR**：C 从 0.1 → 100 单调上升，说明该任务上**弱正则化更有利**——高维稀疏特征本身已具约束力；
- **SVM**：线性核对 C 几乎不敏感（0.9294–0.9328），验证了「文本线性可分性好」； RBF 核更慢且无收益；
- **MLP**：固定 α=1e-3 时隐藏层 50 → 200 几乎无变化（0.9301 → 0.9301）； 真正收益来自**加大 L2 正则化**——α 提高到 0.1 时达 0.9389，说明过拟合才是主要矛盾。



3.4 最终方案、稳定性与误差分析

按「验证准确率最优、0.3% 容差内取复杂度更低者」的规则，最终锁定 **LR（C=100.0, solver=lbfgs）**：在训练集 + 验证集（7,368 条）重训后预测测试集，输出 2,457 条结果（`predictions.csv`，单列无表头，与测试集行序一一对应），预测类别分布 {'0': 270, '1': 243, '2': 233, '3': 243, '4': 247, '5': 249, '6': 246, '7': 248, '8': 245, '9': 233}，与训练分布一致，未出现类别坍缩。 最优模型验证集准确率 **0.9383**、Macro-F1 **0.9385**、 weighted-F1 **0.9385**；10 类中 F1 最低的是类别 2（0.855）， 主要混淆对为 7→2（11）、2→0（7）、2→7（7）。逐条检查误判样本可见，混淆集中在**语义相邻的主题**上 （如硬件讨论 vs 操作系统讨论），这类边界样本连人类读者也需上下文才能判断，属任务本身的模糊地带。





4 结论与局限

结论 ① 预处理强度与性能**并非单调关系**，轻量归一化最优，H1 这一直觉假设被数据否定， 说明预处理决策应交给验证集而不是经验；② IDF 加权是 TF-IDF 生效的关键，更大词表有稳定收益， bigram 在固定维度预算下反而挤占有效特征；③ MLP 的最高验证准确率仅比 LR 高 0.06 个百分点（0.9389 vs 0.9383）， 交叉验证差异（0.9350 vs 0.9318） 也在一个标准差以内，而 LR 的训练代价只有 MLP 的 1/34， 且 MLP 的提升主要来自加大正则化而非加大网络——据此按事先设定的规则选择 LR，支持了 H3。

局限 ① 保留邮件头与引用，本质上是利用了与主题强相关的元信息（发帖机构、被引帖子）， 在同分布测试集上有效，但**跨域/真实场景**下未必可迁移，工程上应重新做消融； ② 测试集无标签，最终性能只能以验证集与交叉验证为代理，存在选择偏差； ③ 交叉验证波动 ±0.0050，表明单次划分的结论需谨慎外推； ④ 未尝试词向量 / 预训练模型表示，是后续最值得探索的方向。

5 实验思考题

Q1 为什么 SVM 和逻辑回归在该数据集上表现很好? TF-IDF 把文档映射到约 3 万维的稀疏空间， 维度数远大于样本数，不同主题的文档几乎总能被一个线性超平面分开（线性可分性好）；同时高维稀疏使核函数 计算代价急剧上升而收益有限，因此线性核 / 线性模型性价比最高。实验中线性 SVM 对 C 几乎不敏感 （0.9294–0.9328）正是这一点的直接证据；LR 与线性 SVM 的决策函数形式几乎一致（log 损失 vs hinge 损失）， 因此表现接近。

Q2 MLP 能否通过加深加宽进一步提升? 是否存在过拟合风险? 本实验给出了直接证据： 固定 α=1e-3 时把隐藏层从 50 加宽到 200，验证准确率仅从 0.9301 变为 0.9301（不升反平）； 真正带来提升的是**加大 L2 正则化**——α 从 1e-3 提到 0.1，准确率由 0.9328 升到 0.9389。 这说明瓶颈不是网络容量，而是**过拟合**：约 3 万维输入、200 个隐藏神经元意味着数百万参数， 而训练样本不足 6 千，模型足以记住训练集却无法泛化。要真正提升 MLP，更有效的是**降低输入维度** （LSA / 词向量替代稀疏 TF-IDF）、加强正则化或早停，而非单纯加深加宽。

Q3 除 TF-IDF 外还有哪些文本表示方法? ① 词袋模型（CountVectorizer）：只统计词频， 本实验 F0 已证明其弱于 TF-IDF；② 主题模型（LSA / LDA）：把文档投影到低维主题空间，可降维去噪； ③ 静态词向量（Word2Vec / GloVe + 平均池化）：引入语义相似性，缓解稀疏问题； ④ 上下文相关表示（BERT 等预训练模型）：当前效果最好，能理解语序与多义词，是本任务最值得尝试的下一步。

全部代码、数据、指标（`results/metrics/*.json|csv`）、图表（`results/figures/*.png`）与运行日志（`results/logs/`）均随仓库提交； 复现命令：`pip install -r requirements.txt && python main.py`（约 40 分钟）。 另有 4 页详版 `report/_archive/报告_4页详版.pdf` 供参考。